

《云计算与大数据应用开发》期末大作业报告

项目名称：基于 RAG 的宝可梦图像知识库检索系统

项目方向：人工智能方向（RAG 智能体：图像知识库检索）

组长：方博闻

组员：林灿仰、卜仕、蔡智杰、罗梓浩

日期：2026年6月25日

一、项目目标

本项目旨在结合**云计算、人工智能与大数据技术**，开发一套基于 RAG（检索增强生成）架构的“宝可梦智能图鉴检索系统”。

最终目的与预期成果：

- 纯自然语言驱动：**摒弃传统的机器编号检索方式，实现 100% 纯自然语言与名称驱动的交互体验，支持口语化、模糊化的特征查询（如“长得像老鼠的黄色电系宝可梦”）。
- 多模态与双语支持：**支持基于图片的视觉检索以及中英文双语查询。
- 云原生高可用架构：**构建稳定、高效、安全的云端基础设施，依托 Docker 容器化部署，解决端口冲突与服务解耦问题。
- 高质量的 LUI 交互体验：**依托大语言模型（LLM）构建具有意图识别能力的智能体，实现闲聊分流与精确图文渲染，提供兼具亲和力与准确性的移动端友好型对话界面。

二、技术选型与运行环境

为满足高并发、低延迟以及大模型推理的资源需求，本项目全面采用了云原生技术栈：

- 云基础设施底座：**阿里云 ECS 通用算力型 u1 实例（4 vCPU, 16 GiB RAM），配备 5 Mbps 按量计费公网带宽。
- 操作系统：**Ubuntu 26.04 64位安全加固版，原生支持现代 Docker 容器特性。
- 容器化与网关：**Docker 负责微服务（9个微服务容器）的隔离与快速部署；Nginx 作为高性能网关处理流量分发与反向代理。

- **一站式 AI 开发平台：** 选用 Dify Community Edition 作为核心开发框架，提供可视化的 RAG 编排、API 管理与 Agent 调试能力。
- **核心模型与向量引擎：**
 - LLM：集成 DeepSeek-v4-flash 与 Qwen（qwen3.6-plus / qwen3.7-max）系列大模型。
 - 向量化与重排：text-embedding-v4（向量化）与 qwen3-rerank（语义重排技术）。

三、 核心实现方案与技术原理

3.1 系统架构：双 Nginx 端口隔离与服务解耦

在单台服务器部署 Dify 应用与 Nginx 媒体资源时，默认会产生 80 端口冲突。本项目通过**服务解耦**解决了该问题：

- **应用服务 (Port 8080)：** 修改 Docker 配置，将 Dify 的 Web 网关入口重映射至 8080 端口，承载复杂的 Agent 工作流调度与 LUI 界面渲染。
- **媒体服务 (Port 80)：** 宿主机直接挂载宝可梦图片数据集目录，由 Nginx 独占 80 端口作为静态资源站。

优势： 确保高频读取高清图片等静态资源时，绝不占用 Dify 应用服务的带宽与 CPU 资源，大幅提升了系统的健壮性与并发能力。

3.2 数据工程：自动化构建高质量语义化数据库

基础数据作为 RAG 系统的基石，我们并未采用简单的原图+文本，而是通过 Python 自动化脚本（build_knowledge.py）重构了物理文件结构，打通了数据存储与语义理解的壁垒：

1. **多线程调用大模型 API：** 利用 ThreadPoolExecutor 开启 25 个并发线程，调用 DeepSeek-Chat API。
2. **自动化双语翻译与扩充：** 自动读取原始中文描述，通过精心设计的 Prompt，将其精准翻译为英文，打破数据语言壁垒。
3. **标准化语义格式封装：** 将数据封装为 “名称+多维属性+视觉描述+资源定位” 的标准化 Markdown 格式。
4. 样例：

凯西，超能力属性，通体黄色，头部外形类似狐狸，尖尖鼻子，手和脚上都有三个指头，长尾巴末端带着一个褐色圆环

Abra, Psychic-type, entirely yellow, with a fox-like head shape, a pointed nose, three fingers on both hands and feet, and a long tail ending in a brown ring.

对应图片: <http://8.160.163.5/0001.png>

5. **精准向量索引**：导入 Dify 的向量数据库中，结合 Jieba 中文分词器，彻底消除了无意义编号的干扰，大幅提升了语义检索的召回率与准确率。

3.3 智能体 workflow 设计：“分流+改写+精排”机制

本项目摒弃了传统单线型 RAG 的局限性，设计了复杂的“意图分流 - 特征提取 - 混合检索 - 语义重排 - 智能生成”的全链路 Agent 闭环结构：

1. **输入接收**：捕捉用户原始 Query。
2. **问题分类器（意图分流）**：引入 DeepSeek-v4-flash 作为前置路由节点。准确判断用户输入是“CLASS 1: 日常闲聊”还是“CLASS 2: 知识库图片检索”。
3. **特征提纯与混合检索**：若为检索意图，由 qwen3.6-plus 对 Query 进行“脱水”与关键词提取；随后在向量数据库中进行混合检索（关键词+向量）。
4. **多模态生成**：引入 qwen3-rerank 优化检索结果顺序，最终由 qwen3.6-plus 融合多模态信息，生成图文并茂的精准回复。



四、产品展示与多维度测试用例

本项目开发了支持移动端自适应的 LUI（Language User Interface）界面，并进行了严格的多维度场景测试，系统表现优异：

4.1 闲聊分流与意图拦截

- **用户输入：**“你好，你叫什么名字？你今天心情怎么样？”
- **系统表现：** 问题分类器成功拦截，判定为闲聊分支。在1秒内给出富有亲和力的自然问候语，未触发空检索的尴尬回复。

4.2 模糊特征查图与容错处理

- **用户输入：**“我想找一个草属性、背上长了颗绿色种子、长得像绿色恐龙的家伙”
- **系统表现：** 系统跨越了命名障碍，准确提纯特征，并成功召回“妙蛙种子”，渲染输出对应的高清图片与完整图鉴。
- **乱序与冗余测试：** 在输入包含大量口语化冗余（如“之前在路上看到的...”）或语序颠倒时，系统依然能自动过滤噪音，精准锁定目标（如锁定“皮卡丘”与“咩利羊”）。

4.3 多模态图片反向检索

- **用户输入：** 上传一张皮卡丘图片，并提问“这只宝可梦是啥？”
- **系统表现：** 通过底层的视觉语言模型（VL）解析图片特征，联动知识库定位，精准返回该宝可梦的中文详细描述。

4.4 批量推荐与英文检索

- **批量查询：** 输入“给我推荐几只黄色的宝可梦”，系统能以规范的 Markdown 列表形式，排版整齐地输出多只对应宝可梦的图文介绍。
- **双语兼容：** 输入英文指令“Find Pikachu and tell me its features”，系统完美识别外文名称并返回对应的中英文整合知识。



五、 总结与展望

项目总结：

本项目不仅成功构建了一套 100% 纯自然语言驱动的宝可梦智能图鉴检索系统，极大降低了用户使用门槛，还充分验证了复杂 Agent 工作流（意图路由+精排）在提升检索准确性上的巨大优势。同时，依托阿里云 ECS 与 Docker 技术，团队攻克了云原生部署与服务端口隔离的难题，积累了宝贵的工程落地经验。

未来展望：

- 1. **模型优化：** 进一步深化探索多模态反向检索机制，全面实现无缝的“以图搜图”交互方式。
- 2. **性能提升：** 持续优化向量数据库检索策略，在保证极致召回率的前提下压缩响应时间，提升系统的并发处理上限。

六、 团队成员分工

姓名	角色/任务	具体工作内容
方博闻	组长 / 系统开发	负责整体项目架构设计、云服务器搭建与 Nginx/Docker 环境配置；编写自动化数据处理 Python 脚本构建知识库；设计 Dify 平台下的

姓名	角色/任务	具体工作内容
		Agent 工作流与大模型接入。
林灿仰	产品汇报文档	负责梳理项目业务逻辑与技术亮点，制作答辩演示用 PPT，并参与大作业最终报告的撰写与排版设计。
卜仕	产品汇报文档	负责梳理项目业务逻辑与技术亮点，制作答辩演示用 PPT，并参与大作业最终报告的撰写与排版设计。
蔡智杰	系统测试	设计并执行多维度测试用例（如闲聊分流、冷门数据测试、多语言测试等），对大模型的输出结果进行评估与校准。
罗梓浩	系统测试	设计并执行多维度测试用例（如闲聊分流、冷门数据测试、多语言测试等），对大模型的输出结果进行评估与校准。